

THEORETICAL-BASED EXAMINATION (MIDTERM)

รายงานสรุปเนื้อหาทฤษฎีและการคำนวณเชิงตัวเลข

Machine Learning: KNN, KNN Regression และ K-Means

พร้อมการวิเคราะห์ขั้นตอนการทำงาน ตัวอย่างการคำนวณมือตามสไลด์ (Step-by-Step) และการแสดงผลเชิงทัศน์ (Visualizations)

รายวิชา MACHINE LEARNING (การเรียนรู้ของเครื่อง)
อาจารย์ผู้สอน: อาจารย์ ดร. โอลาริก สุรินตะ (Olarik Surinta)
คะแนนเต็ม 15 คะแนน | กำหนดส่ง: วันที่ 7 กันยายน เวลา 17:00 น.

รายชื่อสมาชิกในกลุ่ม (จำนวน 5 คน ตามข้อกำหนด)

* ส่งงานโดยหัวหน้ากลุ่มเพียง 1 คน

#	บทบาท	ชื่อ - นามสกุล	รหัสนิสิต	หน้าที่รับผิดชอบ
1	หัวหน้ากลุ่ม	[ชื่อ-สกุล นิสิตคนที่ 1]	[รหัสนิสิต 1]	รวบรวมรายงาน, ส่งไฟล์ PDF, ตรวจสอบภาพรวม
2	สมาชิก	[ชื่อ-สกุล นิสิตคนที่ 2]	[รหัสนิสิต 2]	สรุปทฤษฎี & คำนวณ KNN Classification
3	สมาชิก	[ชื่อ-สกุล นิสิตคนที่ 3]	[รหัสนิสิต 3]	สรุปทฤษฎี & คำนวณ KNN Regression
4	สมาชิก	[ชื่อ-สกุล นิสิตคนที่ 4]	[รหัสนิสิต 4]	สรุปทฤษฎี & คำนวณ K-Means Clustering
5	สมาชิก	[ชื่อ-สกุล นิสิตคนที่ 5]	[รหัสนิสิต 5]	พัฒนา Interactive Visualizations & GitHub Repo

GitHub Repository: [https://github.com/\[username\]/Machine-Learning-Theory-Exam](https://github.com/[username]/Machine-Learning-Theory-Exam)

Online Interactive Dashboard: [https://\[username\].github.io/Machine-Learning-Theory-Exam/](https://[username].github.io/Machine-Learning-Theory-Exam/)

1. K-Nearest Neighbor (KNN) Classification

1.1 ทฤษฎีและแนวคิดพื้นฐาน (Theoretical Concepts)

K-Nearest Neighbor (KNN) เป็นอัลกอริทึมการเรียนรู้แบบมีผู้สอน (Supervised Learning) ที่จัดอยู่ในกลุ่ม **Instance-Based Learning (IBL)** หรือ **Lazy Learning** มีลักษณะสำคัญคือ **ไม่มีขั้นตอนการฝึกฝนเพื่อสร้างแบบจำลองทางคณิตศาสตร์ล่วงหน้า (No explicit model training)** แต่จะเก็บรวบรวมตัวอย่างข้อมูลฝึก (Training Instances) ทั้งหมดไว้ในหน่วยความจำ เมื่อมีข้อมูลทดสอบใหม่เข้ามา (Query Point) จึงจะนำข้อมูลใหม่นั้นไปเปรียบเทียบกับความคล้ายคลึงกับข้อมูลทั้งหมด

แนวคิดรากฐานของ KNN อ้างอิงจากหลักการว่า **"สิ่งที่คล้ายกันมักจะอยู่ใกล้กัน"** (Things that are similar are close to each other) โดยนิยามความคล้ายคลึงผ่านฟังก์ชันวัดระยะทาง (Distance Metric) ในปริภูมิข้อมูล

1.2 การวัดระยะทางและกระบวนการทำงาน 6 ขั้นตอน

ฟังก์ชันวัดระยะทาง (Distance Metrics):

- Euclidean:** $d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$
- Manhattan:** $d(x, y) = \sum_{i=1}^n |x_i - y_i|$
- Minkowski:** $d(x, y) = (\sum_{i=1}^n |x_i - y_i|^p)^{1/p}$

กระบวนการทำงาน 6 ขั้นตอน:

- Input New Sample (รับจุดทดสอบ x)
- Calculate Distance (คำนวณ $d(x, x_i)$)
- Sort Distance (เรียงลำดับน้อย $\rightarrow$ มาก)
- Select K Nearest (เลือกเพื่อนบ้าน K ตัวแรก)
- Majority Vote (ลงคะแนนเสียงคลาส)
- Prediction (เลือกคลาสคะแนนสูงสุด)

1.3 ผลกระทบของการเลือกค่า K (Bias-Variance Tradeoff)

- K ขนาดเล็ก (เช่น K=1):** โมเดลมีความยืดหยุ่นสูง (Flexible) ขอบเขตการตัดสินใจปรับตัวตามข้อมูลได้ละเอียด แต่ข้อเสียคือไวต่อสัญญาณรบกวนมาก (Noise Sensitive) เกิดความแปรปรวนสูง (High Variance / Overfitting)
- K ขนาดใหญ่:** โมเดลมีความเสถียร (Stable) ลดผลกระทบของ Outlier ด้วยการให้คะแนนเสียงจากหลายจุด แต่ข้อเสียคือเสี่ยงต่อ Underfitting ขอบเขตเรียบเกินไป และใช้เวลาคำนวณนาน
- ข้อควรปฏิบัติ:** ในปัญหาจำแนก 2 คลาส ควรเลือก K เป็นเลขคี่ เพื่อป้องกันคะแนนเสียงเท่ากัน (Tie)

1.4 ตัวอย่างการคำนวณตามสไลด์ (สไลด์หน้า 12-13): จุด A ถึง E

ข้อมูลฝึก: $A(2, 3) \in \text{Class A}$, $B(3, 5) \in \text{Class B}$, $C(6, 8) \in \text{Class B}$, $D(7, 6) \in \text{Class B}$, $E(5, 4) \in \text{Class A}$

จุด	พิกัด	Class	ระยะทางถึง $P_1(4, 5)$	ระยะทางถึง $P_2(6, 5)$
A	(2, 3)	Class A	$\sqrt{(4-2)^2 + (5-3)^2} = \sqrt{8} \approx 2.828$ [อันดับ 3]	$\sqrt{(6-2)^2 + (5-3)^2} = \sqrt{20} \approx 4.472$
B	(3, 5)	Class B	$\sqrt{(4-3)^2 + (5-5)^2} = \sqrt{1} = 1.000$ [อันดับ 1]	$\sqrt{(6-3)^2 + (5-5)^2} = \sqrt{9} = 3.000$ [อันดับ 3]
C	(6, 8)	Class B	$\sqrt{(4-6)^2 + (5-8)^2} = \sqrt{13} \approx 3.606$	$\sqrt{(6-6)^2 + (5-8)^2} = \sqrt{9} = 3.000$ [อันดับ 3]
D	(7, 6)	Class B	$\sqrt{(4-7)^2 + (5-6)^2} = \sqrt{10} \approx 3.162$	$\sqrt{(6-7)^2 + (5-6)^2} = \sqrt{2} \approx 1.414$ [อันดับ 1]
E	(5, 4)	Class A	$\sqrt{(4-5)^2 + (5-4)^2} = \sqrt{2} \approx 1.414$ [อันดับ 2]	$\sqrt{(6-5)^2 + (5-4)^2} = \sqrt{2} \approx 1.414$ [อันดับ 2]


ผลการทำนายจุด $P_1(4, 5)$:

เมื่อ $K = 3$ เพื่อนบ้านใกล้สุด 3 ตัวคือ B (Class B), E (Class A), A (Class A)
คะแนนเสียง: Class A ได้ 2 เสียง, Class B ได้ 1 เสียง $\implies$ ทำนาย Class A

ผลการทำนายจุด $P_2(6, 5)$:

เมื่อ $K = 3$ เพื่อนบ้านใกล้สุด 3 ตัวคือ D (Class B), E (Class A) และ B/C (Class B)
คะแนนเสียง: Class B ได้ 2 เสียง ครองเสียงข้างมาก $\implies$ ทำนาย Class B

1.5 ผลลัพธ์และการแสดงผล Visualization (KNN Classification)



รูปที่ 1: แผนภาพแสดงจุดข้อมูลฝึกฝน Class A (สีแดง), Class B (สีน้ำเงินเข้ม) และการพยากรณ์จุดทดสอบ $P_1(4,5)$ ด้วย $K=3$

2. K-Nearest Neighbor (KNN) Regression

2.1 ทฤษฎีและแนวคิดพื้นฐาน (Theoretical Concepts)

KNN Regression เป็นอัลกอริทึมสำหรับพยากรณ์ ค่าตัวเลขต่อเนื่อง (Continuous Target Variable) เช่น ราคาอสังหาริมทรัพย์, ยอดขาย, หรือราคาหุ้น โดยยังคงใช้หลักการค้นหาเพื่อนบ้านที่มีระยะทางใกล้ที่สุด K ตัวในปริภูมิของคุณลักษณะ (Features) แต่เปลี่ยนขั้นตอนการสรุปผลจากการโหวตคลาส มาเป็นการหาค่าเฉลี่ย (Mean) หรือค่าเฉลี่ยถ่วงน้ำหนักตามระยะทาง (Distance-Weighted Average)

2.2 รูปแบบการคำนวณผลลัพธ์ (Formulas)

1. Simple Average (ค่าเฉลี่ยปกติ):

เพื่อนบ้าน K ตัวมีน้ำหนักเท่ากันทั้งหมด:

$$\hat{y} = \frac{1}{K} \sum_{i=1}^K y_i$$

2. Distance-Weighted Average (ถ่วงน้ำหนัก):

เพื่อนบ้านที่ใกล้กว่ามีอิทธิพลต่อค่าทำนายมากกว่า:

$$\hat{y} = \frac{\sum_{i=1}^K w_i y_i}{\sum_{i=1}^K w_i}, \quad w_i = \frac{1}{d_i^p + \epsilon}$$

2.3 ตัวอย่างการคำนวณตามสไลด์ (สไลด์หน้า 27-29): ทำนายราคาบ้าน (Weighted KNN Regression)

จุดทดสอบ: $x = [72 \text{ ตร.ม.}, 2 \text{ ห้องนอน}]$ กำหนด $K = 5, p = 2, \epsilon = 10^{-5}$ คัดเลือกบ้าน 2 ห้องนอนที่ใกล้ที่สุด 5 หลัง:


Index	พื้นที่ (ตร.ม.)	ห้องนอน	ราคาจริง y_i (พันบาท)	ระยะทาง d_i	ค่าน้ำหนัก $w_i = \frac{1}{d_i^2 + 10^{-5}}$	ผลคูณ $w_i \cdot y_i$
7	70	2	1,200	2.00	$\frac{1}{4.00001} \approx 0.2500$	300.00
10	75	2	1,250	3.00	$\frac{1}{9.00001} \approx 0.1111$	138.88
9	65	2	1,150	7.00	$\frac{1}{49.00001} \approx 0.0204$	23.46
3	80	2	1,300	8.00	$\frac{1}{64.00001} \approx 0.0156$	20.28
6	85	2	1,350	13.00	$\frac{1}{169.00001} \approx 0.0059$	7.97
ผลรวม: $\sum w_i = 0.4029$						$\sum w_i y_i = 490.59$

ผลลัพธ์การคำนวณราคาพยากรณ์:


$$\hat{y} = \frac{\sum_{i=1}^5 w_i y_i}{\sum_{i=1}^5 w_i} = \frac{490.59}{0.4029} \approx 1,217.59 \text{ พันบาท (หรือ 1,217,590 บาท)}$$

2.4 การทดลองพยากรณ์ราคาหุ้น Apple (AAPL) ด้วย Sliding Window (Colab)

จากการทดลองตามแนวทางของ Colab 02_Exercise-KNN-Regression.ipynb ได้จำลองการพยากรณ์ราคาปิดหุ้นด้วย Sliding Window ขนาด 5 วัน (ใช้ราคา 5 วันก่อนหน้าพยากรณ์ราคาของวันถัดไป) และประเมินผลด้วย Mean Absolute Error (MAE):



รูปที่ 2: เส้นถดถอยเปรียบเทียบ Simple vs Distance-Weighted บนโจทย์ราคาบ้าน



รูปที่ 3: ผลการทำนายราคาหุ้นด้วย KNN Regression (MAE Simple = 1.83, Weighted = 1.88)

3. K-Means Clustering (การจัดกลุ่มข้อมูล)

3.1 ทฤษฎีและแนวคิดพื้นฐาน (Theoretical Concepts)

K-Means Clustering จัดเป็น Instance-based Unsupervised Learning (การเรียนรู้แบบไม่มีผู้สอน) เนื่องจากชุดข้อมูลไม่มีการระบุป้ายกำกับคลาส (Unlabeled Data) อัลกอริทึมนี้เป็นแบบ Partitioning ที่ทำการแบ่งชุดข้อมูลออกเป็น K กลุ่ม โดยอาศัยระยะห่างระหว่างจุดข้อมูลกับ จุดศูนย์กลางของกลุ่ม (Centroid) มีเป้าหมายเพื่อลดผลรวมความแปรปรวนหรือระยะทางกำลังสองภายในกลุ่ม (Within-Cluster Sum of Squares - WCSS / Inertia)

3.2 ขั้นตอนการทำงาน 5 ขั้นตอน (Algorithm Steps)

- กำหนดค่า K : ระบุจำนวนกลุ่มที่ต้องการแบ่งล่วงหน้า
- กำหนด Initial Centroids: สุ่มหรือระบุตำแหน่งศูนย์กลางเริ่มต้น $C_1, C_2, \dots, C_K$
- Cluster Assignment: คำนวณระยะห่างระหว่างข้อมูลทุกจุดกับ Centroid แล้วมอบหมายให้สังกัด Centroid ที่ใกล้ที่สุด
- Update Centroid: คำนวณจุดศูนย์กลางใหม่จากค่าเฉลี่ยพิกัดของสมาชิกในกลุ่ม: $C_j = \left(\frac{1}{|S_j|} \sum_{x \in S_j} x, \frac{1}{|S_j|} \sum_{y \in S_j} y \right)$
- Iteration: วนทำซ้ำขั้นตอน 3 และ 4 จนตำแหน่ง Centroid ไม่เปลี่ยนแปลง (Convergence)

3.3 ตัวอย่างการคำนวณตามสไลด์ (สไลด์หน้า 8-11): ข้อมูล 2 มิติ จุด A ถึง F

จุดข้อมูล 6 จุด: $A(2, 3), B(3, 4), C(4, 5), D(8, 8), E(9, 9), F(8, 10)$ กำหนด $K = 2$ โดยเริ่มที่ $C_1 = (2, 3), C_2 = (9, 9)$:

จุด	พิกัด	ระยะทางถึง $C_1(2, 3)$	ระยะทางถึง $C_2(9, 9)$	สังกัดกลุ่ม (รอบที่ 1)
A	(2, 3)	$\sqrt{(2-2)^2 + (3-3)^2} = 0.00$	$\sqrt{(2-9)^2 + (3-9)^2} = \sqrt{85} \approx 9.22$	กลุ่ม 1
B	(3, 4)	$\sqrt{(3-2)^2 + (4-3)^2} = \sqrt{2} \approx 1.41$	$\sqrt{(3-9)^2 + (4-9)^2} = \sqrt{61} \approx 7.81$	กลุ่ม 1
C	(4, 5)	$\sqrt{(4-2)^2 + (5-3)^2} = \sqrt{8} \approx 2.83$	$\sqrt{(4-9)^2 + (5-9)^2} = \sqrt{41} \approx 6.40$	กลุ่ม 1
D	(8, 8)	$\sqrt{(8-2)^2 + (8-3)^2} = \sqrt{61} \approx 7.81$	$\sqrt{(8-9)^2 + (8-9)^2} = \sqrt{2} \approx 1.41$	กลุ่ม 2
E	(9, 9)	$\sqrt{(9-2)^2 + (9-3)^2} = \sqrt{85} \approx 9.22$	$\sqrt{(9-9)^2 + (9-9)^2} = 0.00$	กลุ่ม 2
F	(8, 10)	$\sqrt{(8-2)^2 + (10-3)^2} = \sqrt{85} \approx 9.22$	$\sqrt{(8-9)^2 + (10-9)^2} = \sqrt{2} \approx 1.41$	กลุ่ม 2

Centroid ใหม่กลุ่ม 1 {A, B, C}:

$$\bar{x}_1 = \frac{2+3+4}{3} = 3.00, \bar{y}_1 = \frac{3+4+5}{3} = 4.00$$

⇒ C_1 ใหม่ = (3.00, 4.00)


Centroid ใหม่กลุ่ม 2 {D, E, F}:

$$\bar{x}_2 = \frac{8+9+8}{3} \approx 8.33, \bar{y}_2 = \frac{8+9+10}{3} = 9.00$$


⇒ C_2 ใหม่ = (8.33, 9.00)

รอบที่ 2: คำนวณระยะห่างไปยัง $C_1(3.00, 4.00)$ และ $C_2(8.33, 9.00)$ จุดทั้งหมดยังคงสังกัดกลุ่มเดิม สมาชิกไม่เปลี่ยน ตำแหน่ง Centroid จึงคงที่และอัลกอริทึมลู่เข้า (Converged)

3.4 ผลลัพธ์และการแสดงผล Visualization (K-Means Clustering)



รูปที่ 4: การขยับตำแหน่ง Centroid จากจุดเริ่มต้นไปยังพิกัดเฉลี่ยใหม่ (3.00, 4.00) และ (8.33, 9.00)




รูปที่ 5: เปรียบเทียบการประเมิน Good Clustering (เกาะกลุ่มแน่น) vs Poor Clustering (กลุ่มทับซ้อน)

4. บทสรุปเปรียบเทียบและการประยุกต์ใช้งาน (Summary Comparison)

เกณฑ์เปรียบเทียบ	1) KNN Classification	2) KNN Regression	3) K-Means Clustering
Paradigm	Supervised Learning	Supervised Learning	Unsupervised Learning
ชนิดข้อมูลเป้าหมาย	ข้อมูลกลุ่มแยกขาด (Discrete Class)	ข้อมูลตัวเลขต่อเนื่อง (Continuous Target)	ไม่มีข้อมูลเป้าหมาย (No Labels)
การสร้างแบบจำลอง	Lazy Learning (ไม่เทรนล่วงหน้า)	Lazy Learning (ไม่เทรนล่วงหน้า)	Iterative Partitioning (วนหา Centroid)
เกณฑ์การตัดสินใจ	Majority Vote / Weighted Vote	$\frac{1}{K} \sum y_i$ หรือ $\frac{\sum w_i y_i}{\sum w_i}$	Centroid ที่ใกล้ที่สุด ($\min \ x - C_j\ ^2$)
ข้อดีเด่น	เข้าใจง่าย ไม่ต้องเทรน ปรับตัวเร็ว	ทำนายความสัมพันธ์ไม่เป็นเส้นตรงได้ดี	เร็วกับชุดข้อมูลใหญ่ ใช้ทำ EDA ได้เยี่ยม
ข้อพึงระวัง	Curse of Dimensionality, ช้าเมื่อข้อมูลโต	ไวต่อ Outlier, ไม่สามารถทำ Extrapolate	ติด Local Minima จาก Initial Centroids

ตัวอย่างการประยุกต์ใช้จริงในธุรกิจ (Colab 05_K-Means.ipynb):

การวิเคราะห์พฤติกรรมลูกค้าห้างสรรพสินค้า (Customer Segmentation) จากข้อมูล Annual Income และ Spending Score โดยแบ่งเป็น 5 กลุ่ม: 1) รัชมักระวัง (รายได้สูง-ใช้จ่ายต่ำ), 2) มาตรฐาน (ปานกลาง), 3) กลุ่มเป้าหมาย VIP (รายได้สูง-ใช้จ่ายสูง), 4) ประหยัด (รายได้ต่ำ-ใช้จ่ายต่ำ), และ 5) ฟุ่มเฟือย (รายได้ต่ำ-ใช้จ่ายสูง) เพื่อใช้วางแผนการตลาดที่ตรงกลุ่ม



รูปที่ 6: การแบ่งกลุ่มลูกค้าห้างสรรพสินค้า (Mall Customers) 5 คลัสเตอร์ พร้อมจุดทดสอบลูกค้าใหม่ 5 ราย

เอกสารอ้างอิง (References):

- สุรินตะ, โอฟาริก. (2567). เอกสารประกอบการบรรยายรายวิชา Machine Learning: เรื่อง K-Nearest Neighbor (KNN), KNN Regression และ K-Means Clustering.
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction*. Springer.